PrivateMind — Anlage: Modellvergleich europäische LLMs

Raffael Reichelt

Inhaltsverzeichnis

Anlage: Modellvergleich – Europäische Open-Source-LLMs für die PrivateMind-Appliance **1**
Übersichtstabelle 1
Verkaufsargumente je Zielsegment 2
Betriebsempfehlung GX10 2
Risiken / Hinweise 2

Anlage: Modellvergleich – Europäische Open-Source-LLMs für die PrivateMind-Appliance

Stand: Juli 2026 · **Zielplattform:** ASUS Ascent GX10 (NVIDIA GB10 Grace Blackwell, 128 GB Unified Memory) · **Orchestrierung:** nanobot

Übersichtstabelle

Kriterium	Mistral Small 3.x (24B)	Apertus 70B	EuroLLM-22B	Teuken-7B
Herkunft	Mistral AI, Frankreich	Swiss AI Initiative (ETH/EPFL), Schweiz	UTTER / EU-gefördert	OpenGPT-X (Fraunhofer u. a.), Deutschland
Lizenz	Apache 2.0	Offen (Weights, Daten & Training dokumentiert)	Offen (Apache 2.0)	Offen, kommerzielle Nutzung mit Lizenzbedingungen
Parameter	24 Mrd.	70 Mrd.	22 Mrd.	7 Mrd.
Speicherbedarf BF16	~48 GB	~140 GB (passt nicht)	~44 GB	~14 GB
Speicherbedarf Q8	~26 GB	~75 GB	~24 GB	~8 GB
Speicherbedarf Q4/Q5	~14–17 GB	~40–48 GB	~12–15 GB	~4–5 GB
Empf. Betrieb auf GX10	Q8 oder BF16	Q4_K_M / Q5_K_M	Q8	Q8 (falls überhaupt)

Kriterium	Mistral Small 3.x (24B)	Apertus 70B	EuroLLM-22B	Teuken-7B
Tool Calling (nanobot)	✓ Nativ, produktionsreif	(!) Eingeschränkt, weniger ausgereift	(!) Eingeschränkt	× Nicht praxistauglich
Deutsch-Qualität	Sehr gut	Sehr gut	Gut (24 EU-Sprachen)	Gut (24 EU-Sprachen)
Reasoning/Komplexität	Gut (Magistral-Variante: sehr gut)	Gut	Mittel	Schwach
Reifegrad	Produktionsreif	Produktionsnah, Fokus Transparenz	Fortgeschritten	Forschung/Prototyping
Rolle in der Appliance	**Default-Modell** für alle agentischen Workflows	**Souveränitäts-Option** für maximale Transparenz-Anforderungen	Optional: Mehrsprachigkeits-Spezialist	Nicht empfohlen (nur Marketing-Wert)

Verkaufsargumente je Zielsegment

Segment	Primärargument	Passendes Modell
Kanzleien / datensensible Dienstleister	Compliance, Transparenz, Nachvollziehbarkeit	Apertus 70B (voll dokumentiertes Training) + Mistral Small
Handwerksbetriebe	Effizienz, Geschwindigkeit, Zuverlässigkeit	Mistral Small (schnell, stabiles Tool Calling)
EU-weit tätige Kunden	Mehrsprachigkeit	EuroLLM-22B als Zusatzoption

Betriebsempfehlung GX10

- **Standardkonfiguration:** Mistral Small 3.x in Q8 (~26 GB) dauerhaft geladen als nanobot-Backend.
- **Parallelbetrieb möglich:** Mistral Small Q8 + Apertus 70B Q4 (~45 GB) zusammen ~70 GB $\rightarrow$ passt komfortabel in 128 GB Unified Memory inkl. KV-Cache.
- **Kontextlänge einplanen:** KV-Cache wächst mit Kontext; bei langen Dokumenten (Kanzlei-Use-Case) 20–30 GB Reserve vorhalten.
- **Beobachten:** OpenEuroLLM-Initiative – strategisch relevant, Stand Mitte 2026 noch nicht produktionsreif.

Risiken / Hinweise

- Speicherwerte sind Richtwerte; tatsächlicher Bedarf hängt von Runtime (llama.cpp, vLLM, TensorRT-LLM), Kontextlänge und Batch-Größe ab.

- Tool-Calling-Qualität bei Apertus und EuroLLM vor Kundeneinsatz mit den konkreten nanobot-Workflows validieren.
- Modelllandschaft entwickelt sich schnell; Tabelle quartalsweise mit dem Business-Plan-Review aktualisieren.