Anlage: Modellvergleich – Kuratierte LLMs für die PrivateMind-Appliance

Stand: Juli 2026 · **Zielplattform:** ASUS Ascent GX10 (NVIDIA GB10 Grace Blackwell, 128 GB Unified Memory je Gerät, 256 GB im Cluster) · **Orchestrierung:** nanobot

Auswahllogik: Mistral (Frankreich) bleibt die gesetzte europäische Souveränitätsoption und Standard-Empfehlung. Qwen und Llama 4 werden ergänzend kuratiert, weil sie aktuell die stärkste Tool-Calling- *und* Vision-Fähigkeit im Open-Weight-Bereich bieten — beides Grundvoraussetzung für agentische nanobot-Workflows mit Dokumenten- und Bildverständnis. Apertus, EuroLLM und Teuken sind aus der Kernauswahl entfernt (Details siehe Risiken/Hinweise).

Übersichtstabelle

Kriterium	Mistral Small 3.x (24B)	Mistral Large 2 / Pixtral Large (123B)	Qwen3.6-27B	Llama 4 Scout (109B, MoE)
Herkunft	Mistral AI, Frankreich	Mistral AI, Frankreich	Alibaba Cloud, China	Meta, USA
Lizenz	Apache 2.0	Mistral Research License; kommerzieller Einsatz erfordert kostenpflichtige Mistral-Kommerziallizenz	Apache 2.0, keine Nutzungsschwellen	Llama 4 Community License (Sonderbedingungen ab 700 Mio. MAU; für PrivateMind nicht relevant)
Parameter	24 Mrd.	123 Mrd. (+1 Mrd. Vision-Adapter)	27 Mrd. (dense, vollständig aktiv)	109 Mrd. gesamt / 17 Mrd. aktiv (MoE)
Speicherbedarf BF16	~48 GB	~246 GB (passt nicht)	~54 GB	~218 GB (nur Cluster)
Speicherbedarf Q8	~26 GB	~124 GB	~27–29 GB	~115 GB
Speicherbedarf Q4/Q5	~14–17 GB	~62–70 GB	~14–17 GB	~55–60 GB
Empf. Betrieb auf GX10	Q8 oder BF16 (Einzelgerät)	Q4/Q5 auf Einzelgerät, Q8 auf Cluster	Q8 oder BF16 (Einzelgerät)	Q4/Q5 auf Einzelgerät, Q8 auf Cluster
Tool Calling (nanobot)	Nativ, produktionsreif	Nativ, sehr ausgereift	Nativ, sehr ausgereift (SWE-bench/Terminal-Bench auf Claude-Opus-Niveau; volle Unterstützung in vLLM/SGLang)	Nativ, ausgereift
Vision (multimodal)	Ja (seit 3.1)	Ja (als Pixtral Large; Mistral Large 2 selbst text-only)	Ja, nativ integrierter Vision-/Video-Encoder	Ja, nativ von Grund auf multimodal trainiert
Deutsch-Qualität	Sehr gut	Sehr gut	Gut bis sehr gut	Gut
Reasoning / Komplexität	Gut (Magistral-Variante: sehr gut)	Sehr gut	Sehr gut; Kontextfenster 262K nativ, bis 1,01 Mio. Token erweiterbar (Hybrid-Architektur mit linearer Attention)	Sehr gut, zusätzlich sehr großes Kontextfenster
Reifegrad	Produktionsreif	Produktionsreif	Sehr neu (seit April 2026), aber bereits produktionsseitig unterstützt (vLLM, SGLang)	Neu (seit April 2025), produktionsnah; MoE-fähige Runtime nötig

Kriterium	Mistral Small 3.x (24B)	Mistral Large 2 / Pixtral Large (123B)	Qwen3.6-27B	Llama 4 Scout (109B, MoE)
Rolle in der Appliance	**Default-Modell** für Einzel-GX10-Setups	**Premium-Modell** für Cluster-Setups (Premium/Enterprise-Tier)	**Alternatives Default-Modell** für Einzel-GX10-Setups mit Vision-/Langkontext-Schwerpunkt	Ergänzung für sehr lange Dokumente/Kontexte

Verkaufsargumente je Zielsegment

Segment	Primärargument	Passendes Modell
Kanzleien / datensensible Dienstleister	Europäischer Anbieter, Compliance, planbare Lizenzkosten	Mistral Small (Einzelgerät) bzw. Mistral Large/Pixtral Large (Cluster)
Handwerksbetriebe	Effizienz, Geschwindigkeit, Zuverlässigkeit	Mistral Small (schnell, stabiles Tool Calling)
Kunden mit sehr langen Dokumenten/Verträgen	Kontextfenster bis 1 Mio. Token, Bildverständnis, läuft bereits auf Einzelgerät	Qwen3.6-27B
Kunden mit sehr großen Dokumentenbeständen bei geringer Latenzanforderung	Schnelle Inferenz trotz Modellgröße (MoE, nur 17 Mrd. aktiv)	Llama 4 Scout

Betriebsempfehlung GX10

- **Standardkonfiguration Einzelgerät:** Mistral Small 3.x in Q8 (~26 GB) dauerhaft geladen als nanobot-Default (Text und Vision); Qwen3.6-27B in Q8 (~28 GB) als gleichwertige Alternative bei Bedarf an sehr langem Kontext.
- **Standardkonfiguration Cluster:** zusätzlich Mistral Large/Pixtral Large in Q8 (~124 GB) für höhere Qualität bei anspruchsvollen Kanzlei-/Enterprise-Workloads.
- **Parallelbetrieb auf Einzelgerät möglich:** Mistral Small Q8 (~26 GB) + Qwen3.6-27B Q8 (~28 GB) zusammen ~54 GB → passt komfortabel in 128 GB Unified Memory inkl. KV-Cache, auch bei langen Kontexten.
- **Kontextlänge einplanen:** KV-Cache wächst mit Kontext; bei langen Dokumenten (Kanzlei-Use-Case) 20–30 GB Reserve vorhalten.
- **Lizenzkosten einplanen:** Mistral Large/Pixtral Large im kommerziellen Kundenbetrieb erfordert eine kostenpflichtige Mistral-Kommerziallizenz — vor Rollout in Preiskalkulation und Lieferantenverträge einbeziehen.
- **Beobachten:** OpenEuroLLM-Initiative weiterhin beobachten als mögliche künftige souveräne EU-Alternative auf Produktionsniveau, Stand Mitte 2026 noch nicht produktionsreif.

Risiken / Hinweise

- Speicherwerte sind Richtwerte; tatsächlicher Bedarf hängt von Runtime (llama.cpp, vLLM, TensorRT-LLM), Kontextlänge und Batch-Größe ab.
- Llama 4 Scout ist ein MoE-Modell: Es muss trotz nur 17 Mrd. aktiver Parameter der volle Speicherbedarf für alle 109 Mrd. Parameter vorgehalten werden; zudem ist eine MoE-fähige Inference-Runtime erforderlich — Kompatibilität vor Rollout prüfen.
- Lizenzbedingungen vor kommerziellem Einsatz juristisch prüfen: kostenpflichtige Kommerziallizenz bei Mistral Large/Pixtral Large, Community-Lizenzbedingungen bei Llama 4 (Namensnennung, Weitergabepflichten). Qwen3.6-27B läuft unter unbeschränktem Apache 2.0.
- Qwen3.6-27B ist ein sehr junges Release (April 2026); Architektur, Quantisierungen und Tooling entwickeln sich noch schnell — vor Produktivsetzung aktuelle GGUF-/AWQ-Builds und Runtime-Kompatibilität (vLLM/SGLang) prüfen.
- Apertus, EuroLLM und Teuken sind bewusst aus der Kernauswahl ausgeschlossen: Tool-Calling ist bei allen dreien eingeschränkt bis nicht praxistauglich, Vision-Fähigkeit fehlt praktisch vollständig — beides schließt einen sinnvollen Einsatz mit einem Agenten wie nanobot aus. Für reine Text-Souveränitätsanfragen (volle Trainings-Transparenz gefordert, kein Tool-Calling/Vision nötig) bleiben sie als Sonderoption re-evaluierbar.

- Modelllandschaft entwickelt sich schnell; Tabelle quartalsweise mit dem Business-Plan-Review aktualisieren.