Anhang: Modellvergleich Open-Source-LLMs ($\leq$ 35B) für Chat-/RAG-Anwendungen

Dokumenttyp: Technische Entscheidungsgrundlage (Annex zum PrivateMind Founder Book) **Stand:** August 2026 **Kontext:** Auswahl/Absicherung des Chat-LLM für die GX10-Appliance (128 GB Unified Memory) sowie potenzielle Enterprise-Tier-Variante auf Dell EMC (4× L40S) **Aktuelles Produktivmodell:** Mistral Small 3.x 24B (vLLM, Apache 2.0)

---

1. Zielsetzung

Bewertung offener LLMs bis 35B Parameter als Kandidaten für den PrivateMind-Chatstack, mit besonderem Fokus auf:

- Kommerzielle Lizenzverträglichkeit (Analogon zur Jina v4/v5-Problematik)
- Herkunft / Data-Sovereignty-Narrativ (relevant für Kanzlei-Segment)
- Ressourcenbedarf auf vorhandener Hardware (GX10, L40S)
- Chat-/Agenten-Tauglichkeit

---

2. Entscheidungsmatrix

Kriterium	Gewicht	Mistral Small 3.x (24B)	Qwen3-32B	GLM-4-32B	Gemma 3 27B	gpt-oss-20B
Lizenz-Sicherheit (kommerziell, unkritisch)	25%	5 – Apache 2.0	5 – Apache 2.0	3 – je nach Checkpoint, teils Zhipu-Eigenlizenz, prüfpflichtig	2 – Gemma-eigene Lizenz, Einschränkungen	5 – Apache 2.0
Herkunft / Data-Sovereignty-Narrativ	20%	5 – EU (Frankreich)	3 – China, aber lokal betrieben	2 – China (Tsinghua/Zhipu Spin-off), höherer Erklärungsbedarf ggü. Kanzleien	4 – USA (Google)	4 – USA (OpenAI)
Benchmark-Qualität Chat/Agenten	20%	4	5	5	4	4
VRAM-/Ressourcenbedarf auf GX10 (128 GB UM)	15%	5 – etabliert, geringer Headroom-Bedarf	4 – passt komfortabel	4 – passt komfortabel	4 – passt komfortabel	5 – für Single-GPU/kleine Appliance ausgelegt
Ökosystem-Reife (vLLM/Ollama-Support, Tooling)	10%	5 – bereits produktiv integriert	4	3	4	3 – neuer im Ökosystem
Migrationsaufwand (vs. Status quo)	10%	5 – kein Aufwand	3	3	3	3
Gewichteter Gesamtscore	100%	**4,75**	**4,05**	**3,45**	**3,45**	**4,15**

Skala: 1 (schlecht) – 5 (sehr gut). Gewichtung reflektiert PrivateMind-Prioritäten: Lizenzsicherheit und Data-Sovereignty-Narrativ vor reiner Benchmark-Leistung.

3. Kurzprofile

Mistral Small 3.x 24B — *Status quo, Referenzmodell*

- Apache 2.0, EU-Anbieter (Mistral AI, Frankreich) — stärkstes Sovereignty-Narrativ für Kanzlei-Kunden
- Bereits produktiv via vLLM integriert, kein Migrationsrisiko

Qwen3-32B

- Apache 2.0, starke Agenten-/Tool-Use-Fähigkeiten, gute Mehrsprachigkeit
- Herkunft China (Alibaba) — technisch bei On-Premise-Betrieb unkritisch, kommunikativ ggü. Kanzlei-Kunden ggf. erklärungsbedürftig
- Guter Zweitkandidat für internen Benchmark-Vergleich

THUDM GLM-4-32B

- Ursprung: Tsinghua-Universität (KEG-Gruppe), kommerziell getragen von Zhipu AI / Z.ai
- Lizenz uneinheitlich zwischen Checkpoints — **vor Einsatz zwingend Einzelfallprüfung**, analog zur Jina-v4/v5-Regel
- Stärkstes Agenten-Benchmark-Profil in der Vergleichsgruppe, aber höchster Prüf-/Erklärungsaufwand

Gemma 3 27B

- Google, eigene Gemma-Lizenz (nicht Apache/MIT) — Nutzungsbedingungen vor kommerziellem Einsatz prüfen
- Solide Allround-Qualität, aber kein klarer Vorteil ggü. bestehendem Setup

gpt-oss-20B

- OpenAI, Apache 2.0, explizit für kompakte Single-GPU-Appliances ausgelegt — architektonisch gut zur GX10-Philosophie passend
- Jüngstes Modell im Vergleich, Ökosystem-Reife (vLLM/Ollama-Tooling) noch im Aufbau

---

4. Abbruchkriterien für einen Modellwechsel

Ein Wechsel/Ergänzung des Primärmodells wird **nicht** empfohlen, solange:

1. Qualitätsprobleme im Odoo-Chatbot nachweislich auf der Retrieval-Ebene liegen (Jina-Prefixe, Chunking, Reranker-Aktivierung) und nicht auf das LLM zurückzuführen sind
2. Kein dokumentierter Benchmark-Nachweis vorliegt, dass ein Alternativmodell im konkreten PrivateMind-Anwendungsfall (Kanzlei-/Handwerks-Use-Cases) signifikant besser performt
3. Der Migrationsaufwand (Testkatalog-Wiederholung, Prompt-Anpassung, Re-Evaluation) den erwarteten Qualitätsgewinn übersteigt

5. Risikotabelle

Risiko	Eintrittswahrscheinlichkeit	Auswirkung	Gegenmaßnahme
Lizenzänderung bei GLM-4-Checkpoint nach Einsatz	mittel	hoch (rechtliche Neubewertung nötig)	Lizenz pro Checkpoint dokumentieren, Pinning auf feste Version
Kunde (Kanzlei) hinterfragt Modellherkunft China	mittel	mittel (Vertrauensverlust)	Bevorzugt EU/US-Modelle für Kanzlei-Segment kommunizieren, Herkunft transparent im Datenblatt

Risiko	Eintrittswahrscheinlichkeit	Auswirkung	Gegenmaßnahme
Vorschneller Modellwechsel verdeckt eigentliches Retrieval-Problem	hoch (ohne Abbruchkriterien)	hoch (Ressourcenverschwendung)	Abbruchkriterien aus Abschnitt 4 strikt einhalten
Ökosystem-Lücken bei neueren Modellen (gpt-oss-20B) in vLLM/Ollama	niedrig-mittel	mittel (Integrationsaufwand)	Vor Produktivsetzung Kompatibilitätstest im Sandkasten (analog GX10-Pilot)

---

6. Empfehlung

Kurzfristig: Mistral Small 3.x 24B als Primärmodell beibehalten — höchster Gesamtscore, kein Migrationsrisiko, stärkstes Data-Sovereignty-Narrativ für das Kanzlei-Segment.

Mittelfristig (nach Abschluss Retrieval-Debugging): Qwen3-32B als internen Vergleichskandidaten evaluieren (zweithöchster Score, unkritische Lizenz), primär für das Handwerks-Segment, wo Data-Sovereignty-Narrativ weniger geschäftskritisch ist als reine Leistungsfähigkeit.

Nicht empfohlen für Kanzlei-Kunden ohne weitere Prüfung: GLM-4-32B (Lizenzunsicherheit) und Gemma 3 27B (restriktivere Lizenzbedingungen).